

INFORME
Evaluación práctica de la Unidad 1: Reconociendo lo aprendido

Grupo # 2

Miembros

Mariana López Díaz.

Jhorman Vallejo.

Sara Ximena Machado.

Caso de Estudio: Empresa “Gaseosas Poderosas”


1. -Descripción de la Tarea

En el proyecto académico se llevó a cabo el proceso de diseño, migración, transformación e integración de la información heterogénea y dispersa de la empresa **Gaseosas Poderosas**, hacia una base de datos relacional centralizada en PostgreSQL. El trabajo abarcó las siguientes actividades:

1. **Diseño Conceptual y Lógico de la Base de Datos:** Construcción del diagrama de Entidad-Relación de Chen y normalización de las tablas del dominio transaccional y territorial.
2. **Proceso ETL (Extracción, Transformación y Carga):** Implementación de scripts en Python para extraer datos territoriales del DANE (colombia-dane-departamentos.csv), transformar los identificadores a enteros simples con la estructura de códigos de país (\$57\$) y cargar las tablas maestras y de ventas.
3. **Limpieza e Imputación de Datos:** Profiling y saneamiento de 10.000 registros transaccionales en la tabla operaciones, identificando y reparando fallas de formato en fechas, cantidades nulas o negativas, y omisión de códigos clave.
4. **Análisis y Consultas SQL:** Formulación de consultas analíticas sobre la vista unificada vista_operaciones para evaluar el desempeño comercial por región, departamento, municipio y producto.
5. **Gráficos y Visualización:** Elaboración de diagramas analíticos (Pareto de ventas por departamento y sectores por producto) para soportar la toma de decisiones gerenciales.

2. -Diagrama de Entidad -Relación (Diagrama de Chen)

https://drive.google.com/file/d/1LgYKrAW0_kmXQIfROQ09j-ZyECNFKjNU/view?usp=sharing



3.- Diccionario de Datos

Tabla regiones:

Llave primaria: id_region

Campo	Tipo de Dato	Tamaño	PK	FK	Claves Únicas.	Relacion con otras tablas	Descripción
id_region	Integer	4 bytes	Si	No	Si	Departamentos (1:N)	identificador único de la región
nombre	Varchar	50	No	No	Si	Ninguna	Nombre de la región.

Tabla departamentos:

Llave primaria: id_departamentos.

Llave foráneas: id_region.

Campo	Tipo de dato	Tamaño	PK	FK	Claves Unicas.	Relación	Descripción
id_departamento	Integer	4 bytes	Si	No	Si	Municipios (1:N) Operaciones (1:N)	Codigo estructurado(57 + sufijo DANE)
nombre	Varchar	70	No	No	No	Ninguna.	Nombre oficial del departamento.
codigo_region	Integer	4 bytes	No	Si	No	Regiones (id_region)	Código de la región asociada.

Tabla municipios:

Llave primaria: id_municipio.

Llaves Foráneas: id_departamento.

Campo	Tipo de Dato	Tamaño	PK	FK	Clave Única.	Relación	Descripción
id_municipio	Integer	4 bytes	Si	No	Si	Operaciones(1:N)	Código estructurado (57 + dep + secuencial)
id_departamento	Integer	4 bytes	No	No	No	Departamento (id_departamento)	Código del Departamento perteneciente.

I.U. PASCUAL BRAVO
ET-0155 – Fundamentos de Big Data – Grupo 0100
Periodo 2026-2
Profesor: León Marín López

nombre_municipio	Varchar	70	No	Si	No	Ninguna	Nombre oficial del municipio.
------------------	---------	----	----	----	----	---------	-------------------------------

Tabla productos:

Llave Primaria: id_producto.

Campo	Tipo de Dato	Tamaño	PK	FK	Clave Unica	Relaciones	Descripción
id_producto	Integer	4 bytes	Si	No	Si	Operaciones (1:N)	Código identificador del producto.
nombre	Varchar	20	No	No	Si	Ninguna	Nombre del portafolio.
precio	Decimal	10,2	No	No	Si	Ninguna	Precio unitario de venta.

Tabla operaciones:

Llave Primaria: id_registro.--

Llaves Foráneas: id_departamento, id_municipio, id_producto

Campo	Tipo de Dato	Tamaño	PK	FK	Claves Unicas.	Relaciones	Descripción
id_registro	INTEGER	4 bytes	Si	No	Si	Ninguna	Número de transacción.
id_departamento	INTEGER	4 bytes	No	Si	No	Departamento (id_departamento)	Código DANE del departamento.
id_municipio	INTEGER	4 bytes	No	Si	No	Municipio (id_municipio)	Código DANE del municipio.
id_producto	INTEGER	4 bytes	No	Si	No	Productos (id_producto)	Código de producto vendido.
fecha	DATE	10	No	No	No	Ninguna	Fecha de la operación en formato YYYY-MM-DD
monto_total	DECIMAL		No	No	No	Ninguna	Valor total de la venta.
cantidad	INTEGER	4 bytes	No	No	No	Ninguna	Cantidad de unidades vendidas.


I.U. PASCUAL BRAVO
ET-0155 – Fundamentos de Big Data – Grupo 0100
Periodo 2026-2
Profesor: León Marín López

fue_modificado	BOOLEAN	1 bytes	No	No	No	Ninguna	Indicador de modificación durante ETL/limpieza.
causa_modificacion	VARCHAR	100	No	No	No	Ninguna	Descripción de la anomalía corregida

4.- Corrida del algoritmo ETL

Se ejecutó algoritmo-etl.py. El programa lee colombia-dane-departamentos.csv, archivo del DANE con región, departamento, municipio y códigos DANE. getCodigoRegion() asigna a cada región un número del 1 al 6. La llave del departamento se arma con el indicativo 57 más el código DANE de dos dígitos: Antioquia queda 5705. La llave del municipio agrega un consecutivo de tres dígitos: 5705001. Primero carga la tabla temporal y después departamentos y municipios. Resultado: 33 departamentos y 1.123 municipios.

Captura de conteo de departamentos y municipios



The screenshot shows the pgAdmin 4 interface. On the left, the Object Explorer shows the database structure. The main pane displays a SQL query:

```
1 SELECT
2   (SELECT COUNT(*) FROM departamentos) AS departamentos,
3   (SELECT COUNT(*) FROM municipios) AS municipios;
4
5
6
```

Below the query, the Data Output tab shows the results:

	departamentos bigint	municipios bigint
1	33	1123

Captura fin de proceso ETL



The screenshot shows a PowerShell terminal window with the following output:

```
Carga de municipios: contador, sufijo, id_dep, id_mun, nom_mun, cod_mun: 3 003 5797 5797003 Pacoa 97.511
Carga de municipios: contador, sufijo, id_dep, id_mun, nom_mun, cod_mun: 4 004 5797 5797004 Papunahua 97.777
Carga de municipios: contador, sufijo, id_dep, id_mun, nom_mun, cod_mun: 5 005 5797 5797005 Taraira 97.666
Carga de municipios: contador, sufijo, id_dep, id_mun, nom_mun, cod_mun: 6 006 5797 5797006 Yavarate 97.889
Carga de municipios: contador, sufijo, id_dep, id_mun, nom_mun, cod_mun: 1 001 5799 5799001 Cumaribo 99.773
Carga de municipios: contador, sufijo, id_dep, id_mun, nom_mun, cod_mun: 2 002 5799 5799002 La Primavera 99.524
Carga de municipios: contador, sufijo, id_dep, id_mun, nom_mun, cod_mun: 3 003 5799 5799003 Puerto Carreño 99.001
Carga de municipios: contador, sufijo, id_dep, id_mun, nom_mun, cod_mun: 4 004 5799 5799004 Santa Rosalia 99.624
Conexión PostgreSQL cerrada
Fin del proceso ETL
PS C:\Users\Jhorman Vallejo\Desktop\tarea ETL bigdata>
```

5- Modificar el algoritmo ETL para incluir datos de región.

Se creó la tabla regiones con las seis regiones de Colombia. En operaciones se agregaron id_region, fue_modificado y causa_modificacion. id_region se copió desde departamentos.codigo_region. Ese UPDATE actualizó 9.995 ventas.

Las 5 restantes tenían el departamento en cero y recibieron la región después de la limpieza de la sección 6. La vista vista_operaciones se actualizó para incluir el nombre de la región, porque la consulta 7.5 lo necesita. SQL utilizado:

```
CREATE TABLE IF NOT EXISTS public.regiones (  
    id_region INTEGER NOT NULL,  
    nombre VARCHAR(50) NOT NULL,  
    CONSTRAINT regiones_pkey PRIMARY KEY (id_region)  
);  
  
INSERT INTO public.regiones (id_region, nombre) VALUES  
  
(1, 'Region Eje Cafetero - Antioquia'),  
  
(2, 'Region Centro Oriente'),  
  
(3, 'Region Centro Sur'),  
  
(4, 'Region Caribe'),  
  
(5, 'Region Llano'),  
  
(6, 'Region Pacifico');  
  
ALTER TABLE public.operaciones ADD COLUMN IF NOT EXISTS id_region INTEGER;  
  
ALTER TABLE public.operaciones ADD COLUMN IF NOT EXISTS fue_modificado BOOLEAN DEFAULT FALSE;  
  
ALTER TABLE public.operaciones ADD COLUMN IF NOT EXISTS causa_modificacion VARCHAR(100) DEFAULT  
'NINGUNA';  
  
UPDATE public.operaciones o  
  
SET id_region = d.codigo_region  
  
FROM public.departamentos d  
  
WHERE o.id_departamento = d.id_departamento;
```

6.- Detectar registros con problemas. Transformación de datos (limpieza, modificación, imputación)

Se revisaron los 10.000 registros de operaciones. Había 30 con error, en cinco tipos. No se borró ningún registro: todos se corrigieron con SQL. fue_modificado quedó en verdadero y causa_modificacion indica el motivo. Después de la limpieza, vista_operaciones devuelve los mismos 10.000 registros que la tabla operaciones.

Tipo de problema	Número o Registro	Campo (BD)	Problema detectado	Solución
A	10001	fecha	2024-8-21	Corregida a 2024-08-21
A	11599	fecha	24-02-08	Corregida a 2024-02-08

I.U. PASCUAL BRAVO
ET-0155 – Fundamentos de Big Data – Grupo 0100
Periodo 2026-2
Profesor: León Marín López

A	12110	fecha	024-07-17	Corregida a 2024-07-17
A	13945	fecha	13-12-2024	Corregida a 2024-12-13
A	14368	fecha	24-28-10	Corregida a 2024-10-28
A	15955	fecha	24-27-09	Corregida a 2024-09-27
A	16558	fecha	01-02-24	Corregida a 2024-02-01
A	17125	fecha	12-12-2024	Corregida a 2024-12-12
A	18056	fecha	24-09-09	Corregida a 2024-09-09
A	19680	fecha	11-23-2024	Corregida a 2024-11-23
B	10225	cantidad	Valor 0	Promedio del municipio: 136
B	13161	cantidad	Valor 0	Promedio del municipio: 105
B	15412	cantidad	Valor 0	Promedio del municipio: 79
B	17528	cantidad	Valor 0	Promedio del municipio: 79
B	19181	cantidad	Valor 0	Promedio del municipio: 107
C	10014	cantidad	Valor -198	Valor absoluto: 198
C	11907	cantidad	Valor -144	Valor absoluto: 144
C	15208	cantidad	Valor -175	Valor absoluto: 175
C	18126	cantidad	Valor -181	Valor absoluto: 181
C	19538	cantidad	Valor -112	Valor absoluto: 112
D	10326	id_departament o	Código en 0	Quedó 5715, tomado del municipio 5715051
D	12188	id_departament o	Código en 0	Quedó 5715, tomado del municipio 5715120
D	14020	id_departament o	Código en 0	Quedó 5723, tomado del municipio 5723027
D	16635	id_departament o	Código en 0	Quedó 5741, tomado del municipio 5741019
D	18469	id_departament o	Código en 0	Quedó 5763, tomado del municipio 5763011
E	10686	id_producto	Código en 0, Támesis	Se asignó 4, NARANJITA
E	11734	id_producto	Código en 0, Támesis	Se asignó 4, NARANJITA

I.U. PASCUAL BRAVO
ET-0155 – Fundamentos de Big Data – Grupo 0100
Periodo 2026-2
Profesor: León Marín López

E	17341	id_producto	Código en 0, Tamesis	Se asignó 4, NARANJITA
E	18911	id_producto	Código en 0, Tamesis	Se asignó 4, NARANJITA
E	19195	id_producto	Código en 0, Tamesis	Se asignó 4, NARANJITA

Código que se utilizó para corregir los registros:

-- 1. Cantidades negativas

UPDATE operaciones

SET cantidad = ABS(cantidad),

fue_modificado = TRUE,

causa_modificacion = 'CANTIDAD NEGATIVA'

WHERE cantidad < 0;

-- 2. Departamento en cero

UPDATE operaciones

SET id_departamento = id_municipio / 1000,

fue_modificado = TRUE,

causa_modificacion = 'DEPARTAMENTO EN CERO'

WHERE id_departamento = 0;

-- 3. Region de los departamentos que estaban en cero

UPDATE operaciones o

SET id_region = d.codigo_region

FROM departamentos d

WHERE o.id_region IS NULL

AND o.id_departamento = d.id_departamento;

-- 4. Producto en cero. En Tamesis solo se vende NARANJITA

UPDATE operaciones

SET id_producto = 4,

fue_modificado = TRUE,

```
causa_modificacion = 'PRODUCTO EN CERO'

WHERE id_registro IN (10686, 11734, 17341, 18911, 19195);

-- 5. Cantidad en cero

UPDATE operaciones o

SET cantidad = sub.promedio,

    fue_modificado = TRUE,

    causa_modificacion = 'CANTIDAD EN CERO'

FROM (

    SELECT id_municipio, ROUND(AVG(cantidad))::integer AS promedio

    FROM operaciones

    WHERE cantidad > 0

    GROUP BY id_municipio

) sub

WHERE o.cantidad = 0

AND o.id_municipio = sub.id_municipio;

-- 6. Fechas incorrectas

UPDATE operaciones

SET fecha = CASE id_registro

    WHEN 10001 THEN '2024-08-21'

    WHEN 11599 THEN '2024-02-08'

    WHEN 12110 THEN '2024-07-17'

    WHEN 13945 THEN '2024-12-13'

    WHEN 14368 THEN '2024-10-28'

    WHEN 15955 THEN '2024-09-27'

    WHEN 16558 THEN '2024-02-01'

    WHEN 17125 THEN '2024-12-12'

    WHEN 18056 THEN '2024-09-09'
```

```

WHEN 19680 THEN '2024-11-23'

END,

fue_modificado = TRUE,

causa_modificacion = 'FECHA INCORRECTA'

WHERE id_registro IN (10001, 11599, 12110, 13945, 14368, 15955, 16558, 17125, 18056, 19680);

```

7.- Tabla de consultas SQL

Las seis consultas se hicieron sobre vista_operaciones, después de la limpieza. La vista devuelve 10.000 registros, la misma cantidad que la tabla operaciones.

#	Descripción	Consulta SQL
7.1	Seleccionar los 8 departamentos con mayor <u>volumen</u> de ventas (monto) de productos ordenados de mayor a menor. Datos solicitados: nombre de departamento y monto total por departamento de todos los productos. Nota: Recuerde que tiene agrupar por departamento	<pre> SELECT departamento, SUM(venta) AS total_monto FROM vista_operaciones GROUP BY departamento ORDER BY total_monto DESC LIMIT 8; </pre> Resultado: Antioquia 105.759.800 Boyaca 99.513.900 Cundinamarca 93.349.300 Santander 73.633.600 Nariño 54.167.600 Bolívar 40.279.200 Tolima 39.817.700 Valle del Cauca 36.605.600
7.2	Seleccionar los 15 municipios con mayor <u>cantidad</u> de productos vendidos en el departamento de Antioquia ordenados de mayor a menor. Datos solicitados: nombre municipio y cantidad total por municipio. Nota: Recuerde que tiene agrupar por municipio	<pre> SELECT municipio, SUM(cantidad) AS total_cantidad FROM vista_operaciones WHERE departamento = 'Antioquia' GROUP BY municipio ORDER BY total_cantidad DESC LIMIT 15; </pre> Resultado: Valdivia 1.850; Turbo 1.708; Sopetran 1.699; Nariño 1.611; Cáceres 1.604; Amaga 1.600; Frontino 1.520; Puerto Berrio 1.514; Anorí 1.510; Dabeiba 1.441; Amalfi 1.430; Belmira 1.412; San Pedro de Urabá 1.399; Venecia 1.391; Arboletes 1.380


7.3	Seleccionar los 5 departamentos con mayor cantidad de gaseosas vendidas del producto “MANZALOCA” ordenados de mayor a menor. Datos solicitados: nombre de departamento y cantidad total por departamento. Nota: Recuerde que tiene agrupar por departamento y filtrar por el producto.	<pre>SELECT departamento, SUM(cantidad) AS total_manzaloca FROM vista_operaciones WHERE producto = 'MANZALOCA' GROUP BY departamento ORDER BY total_manzaloca DESC LIMIT 5;</pre> Resultado: Antioquia 27.305 Boyaca 26.577 Cundinamarca 25.510 Santander 21.376 Nariño 14.273
7.4	Seleccione los 5 municipios con el menor monto de ventas de gaseosas ordenados de menor a mayor. Datos solicitados: nombre del departamento al que pertenece, nombre municipio y monto total de ventas por municipio. Nota: Recuerde que tiene agrupar por municipio	<pre>SELECT departamento, municipio, SUM(venta) AS total_monto FROM vista_operaciones GROUP BY departamento, municipio ORDER BY total_monto ASC LIMIT 5;</pre> Resultado: Valle del Cauca, Zarzal, 68.200 Cesar, Pelaya, 86.400 Boyaca, Toghñi, 92.800 Cordoba, Moñitos, 94.200 Cundinamarca, Sesquile, 104.200
7.5	Consultar la cantidad de gaseosas vendidas de cada producto por cada región ordenados de mayor a menor.	<pre>SELECT region, producto, SUM(cantidad) AS total_cantidad FROM vista_operaciones GROUP BY region, producto ORDER BY total_cantidad DESC;</pre> Resultado: 24 filas. La mayor es Region Centro Oriente, MANGOSON, 83.105. La menor es Region Llano, MANGOSON, 14.054.
7.6	Consultar el total del monto de ventas de cada producto en Antioquia de mayor a menor.	<pre>SELECT producto, SUM(venta) AS total_monto FROM vista_operaciones WHERE departamento = 'Antioquia' GROUP BY producto ORDER BY total_monto DESC;</pre>

		Resultado: COLOMBIANITA 35.680.800 MANZALOCA 27.305.000 MANGOSON 24.820.200 NARANJITA 17.953.800
--	--	---

8.- Gráficos


8.1.- Gráfico de Pareto que muestra los resultados de la consulta #7.1.

8.1.1.- Resultados de la consulta.



departamento	total_monto
Antioquia	105759800
Boyacá	99513900
Cundinamarca	93349300
Santander	73653600
Nariño	54167600
Bolívar	40279200
Tolima	39817700
Valle del Cauca	36605600


8.1.2.- Gráfico.



8.2.- Gráfico de Pareto que muestra los resultados de la consulta #7.2.

8.2.1.- Resultados de la consulta.

I.U. PASCUAL BRAVO
ET-0155 – Fundamentos de Big Data – Grupo 0100
Periodo 2026-2
Profesor: León Marín López




Query History

```
1 SELECT municipio, SUM(cantidad) AS total_cantidad
2 FROM vista_operaciones
3 WHERE departamento = 'Antioquia'
4 GROUP BY municipio
5 ORDER BY total_cantidad DESC
6 LIMIT 15;
```

Data Output


municipio	total_cantidad
Valdivia	1850
Turbo	1708
Sopetrán	1699
Nariño	1611
Cáceres	1604
Amagá	1600
Frontino	1520
Puerto Berrío	1514
Anorí	1510
Dabeiba	1441
Amalfi	1430
Belmira	1412
San Pedro de Urabá	1399
Venecia	1391
Arboletes	1380

8.2.2.- Gráfico.



8.3.- Gráfico de Pareto que muestra los resultados de la consulta #7.3.

8.3.1.- Resultados de la consulta.




Query History

```
1 SELECT departamento, SUM(cantidad) AS total_manzaloca
2 FROM vista_operaciones
3 WHERE producto = 'MANZALOCA'
4 GROUP BY departamento
5 ORDER BY total_manzaloca DESC
6 LIMIT 5;
```

Data Output


departamento	total_manzaloca
Antioquia	27305
Boyacá	26577
Cundinamarca	25510
Santander	21376
Nariño	14273

8.3.2.- Gráfico.




8.4.- Gráfico de Pareto que muestra los resultados de la consulta #7.4.

8.4.1.- Resultados de la consulta.



8.4.2.- Gráfico.



8.5.- Gráfico de Tortas que muestra los resultados de la consulta #7.5.


8.5.1.- Resultados de la consulta.

I.U. PASCUAL BRAVO
ET-0155 – Fundamentos de Big Data – Grupo 0100
Periodo 2026-2
Profesor: León Marín López

The screenshot shows the pgAdmin 4 interface. On the left, the 'Object Explorer' shows a tree structure with 'Servers (1)' containing 'PostgreSQL 18', which has 'Databases (2)' including 'bigdata'. The 'Query' tab is active, displaying a SQL query:
`1 SELECT region, producto, SUM(cantidad) AS total_cantidad
2 FROM vista_operaciones
3
4
5`
The 'Data Output' pane shows the results of the query, displaying 24 rows. The columns are 'region', 'producto', and 'total_cantidad'. The data is grouped by region and product. The regions included are Centro Oriente, Caribe, Eje Cafetero, Pacifico, and Llano. The products included are MANGOSON, MANZALOCA, NARANJITA, and COLOMBIANITA. The total_cantidad values range from 14354 to 83105. The status bar at the bottom indicates 'Total rows: 24' and 'Query complete 00:00:00.199'.

region	producto	total_cantidad
Region Centro Oriente	MANGOSON	83105
Region Centro Oriente	MANZALOCA	82590
Region Centro Oriente	NARANJITA	82514
Region Centro Oriente	COLOMBIANITA	78099
Region Caribe	NARANJITA	47774
Region Caribe	COLOMBIANITA	44702
Region Caribe	MANGOSON	44699
Region Pacifico	MANGOSON	43559
Region Pacifico	COLOMBIANITA	42949
Region Caribe	MANZALOCA	42727
Region Eje Cafetero - Antioq...	COLOMBIANITA	41966
Region Eje Cafetero - Antioq...	NARANJITA	41405
Region Pacifico	NARANJITA	39984
Region Pacifico	MANZALOCA	39671
Region Eje Cafetero - Antioq...	MANGOSON	39231
Region Eje Cafetero - Antioq...	MANZALOCA	38989
Region Centro Sur	NARANJITA	29775
Region Centro Sur	MANZALOCA	28327
Region Centro Sur	MANGOSON	28248
Region Centro Sur	COLOMBIANITA	27858
Region Llano	MANZALOCA	16444
Region Llano	NARANJITA	15595
Region Llano	COLOMBIANITA	14430
Region Llano	MANGOSON	14354

8.5.2.- Gráfico.




8.6.- Gráfico de Torta que muestra los resultados de la consulta #7.6.

8.6.1.- Resultados de la consulta.

The screenshot shows the pgAdmin 4 interface. On the left, the 'Object Explorer' shows a tree structure with 'Servers (1)' containing 'PostgreSQL 18', which has 'Databases (2)' including 'bigdata'. The 'Query' tab is active, displaying a SQL query:
`1 SELECT producto, SUM(venta) AS total_monto
2 FROM vista_operaciones
3 WHERE departamento = 'Antioquia'
4 GROUP BY producto
5 ORDER BY total_monto DESC;
6`
The 'Data Output' pane shows the results of the query, displaying 4 rows. The columns are 'producto' and 'total_monto'. The products included are COLOMBIANITA, MANZALOCA, MANGOSON, and NARANJITA. The total_monto values range from 17953800 to 35680800. The status bar at the bottom indicates 'Showing rows: 1 to 4' and 'Page No: 1 of 1'.

producto	total_monto
COLOMBIANITA	35680800
MANZALOCA	27305000
MANGOSON	24820200
NARANJITA	17953800

8.6.2.- Gráfico.



10.- Determinar el tiempo y tamaño de procesamiento de un conjunto de registros.

Se modificó algoritmo-calculo-tamano.py para medir el tiempo con time.perf_counter(), desde el inicio de la carga hasta el final, y para consultar el tamaño de la base bigdata. Cada corrida borra la tabla tamaño y la vuelve a llenar. La fila de 10.000.000 no se ejecutó ya que el programa del profesor pide 10.000, 100.000 y 1.000.000.

Cantidad de registros	Tiempo de procesamiento (milisegundos)	Tamaño tabla "tamano" (kilobytes)	Tamaño Base de Datos "bigdata" (Kilobytes o MegaBytes)	Porcentaje de almacenamiento de "tamano" con respecto al total de la base de datos
10.000	7.695,671	696 kB	11 MB	6,18 %
100.000	75.945,145	6.704 kB	17 MB	38,51 %
1.000.000	810.165,579	65 MB	75 MB	86,67 %
10.000.000	No ejecutada			

11. Análisis de Resultados e Insights Estratégicos

Para: Junta Directiva – Gaseosas Poderosas

De: Equipo de Ciencia de Datos & Business Intelligence

Asunto: Informe Ejecutivo de Hallazgos Transaccionales y Recomendaciones Estratégicas

Resumen Ejecutivo

Tras el procesamiento, limpieza (ETL) y modelado tridimensional (3FN) de nuestro historial transaccional de 10.000 registros, presentamos los hallazgos clave derivados del análisis exploratorio de datos. Este informe traduce los patrones de consumo en **decisiones tácticas de negocio** destinadas a maximizar la rentabilidad, optimizar la cadena de distribución y recuperar cuota de mercado en regiones subdesarrolladas.

1. Hallazgos Principales (Insights de Ciencia de Datos)

A. Liderazgo Consolidado de Antioquia y la Región Centro Oriente

- **El Hallazgo:** Antioquia encabeza las ventas nacionales con un monto total de **\$105.759.800 COP** (19,3% del total acumulado), impulsado por la alta densidad poblacional y la fuerte penetración de la marca en municipios clave como Valdivia y Turbo. La Región **Centro Oriente** representa la mayor fuerza comercial con **221.840 unidades** comercializadas.
- **Diagnóstico:** Existe una alta fidelización de marca y una red de distribución logística altamente eficiente en los nodos principales de esta región.

B. Anomalía Poblacional: Boyacá vs. Valle del Cauca y Atlántico

- **El Hallazgo:** Boyacá ocupa el 2.º lugar nacional en ventas con **\$99.513.900 COP**, superando significativamente a departamentos con mayor densidad demográfica e industrial como el Valle del Cauca (**\$36.605.600 COP**, posición 8) o departamentos de la Costa Caribe.
- **Diagnóstico:** Esta divergencia sugiere dos factores críticos:
 1. **Efecto Muestral/Saturación:** Boyacá presentó una cobertura de rutas de distribución más agresiva y libre de competidores directos durante el periodo.
 2. **Subpenetración en el Valle del Cauca:** La baja venta en el Valle indica fallas en la cadena de frío, cuellos de botella en la distribución local o una preferencia arraigada hacia competidores regionales, lo que representa una **pérdida de oportunidad comercial**.

C. Preferencia de Portafolio: El Fenómeno "COLOMBIANITA" y "MANZALOCA"

- **El Hallazgo:** En Antioquia, el producto **COLOMBIANITA** genera el **33.7%** del ingreso por ventas (\$35.680.800 COP), seguido de **MANZALOCA (25.8%)**. MANZALOCA demuestra un comportamiento de ventas transversalmente sólido en todo el territorio nacional, sumando 27.305 unidades vendidas solo en la región antioqueña.
- **Diagnóstico:** COLOMBIANITA actúa como el "producto insignia" (Cash Cow), mientras que MANZALOCA muestra un crecimiento constante independiente del tipo de clima o región geográfica.

D. Diagnóstico de Municipios Críticos (Datos Atípicos Inferiores)

- **El Hallazgo:** Municipios como **Zarzal (Valle del Cauca)** con apenas **\$68.200 COP**, **Pelaya (Cesar)** con **\$86.400 COP**, y **Togüí (Boyacá)** registran ventas atípicamente bajas, ubicándose en la cola de la distribución muestral.
- **Diagnóstico:** La presencia de valores tan bajos responde a tres causas probables:
 - **Problemas de Calidad de Datos (ETL):** Modificaciones o imputaciones severas durante la etapa de limpieza de datos por inconsistencias en los registros de venta.
 - **Falta de Fuerza de Ventas:** Rutas de entrega intermitentes que no abastecen a los tenderos locales con la frecuencia requerida.

2. Matriz de Recomendaciones y Plan de Acción

A partir de las pinceladas analíticas obtenidas, proponemos a la Junta Directiva el siguiente plan de acción estructurado:

I.U. PASCUAL BRAVO
ET-0155 – Fundamentos de Big Data – Grupo 0100
Periodo 2026-2
Profesor: León Marín López

Dimensión	Hallazgo Crítico	Acción Recomendada	Impacto Esperado
Expansión de Mercado	Subpenetración en Valle del Cauca y Pacífico.	Implementar un Plan de Choque Comercial en el Valle del Cauca, aliándose con distribuidores mayoristas locales y lanzando campañas de promoción agresivas.	Incremento estimado del 25% a 35% en las ventas de la región Pacífico en el próximo trimestre.
Optimización de Portafolio	Dominio de COLOMBIANITA (33.7%) y fortaleza de MANZALOCA.	Asegurar stock prioritario en planta para COLOMBIANITA. Diseñar combos/empaques cruzados de MANZALOCA + NARANJITA (producto con menor rotación, 17%).	Incremento del margen del portafolio al impulsar los productos de menor rotación en la cesta de compra.
Logística y Cadena de Suministro	Ventas atípicamente bajas en municipios periféricos (Zarzal, Pelaya).	Rediseñar las rutas micro-logísticas y establecer convenios con logística de terceros (3PL) para cubrir municipios remotos sin elevar costos fijos.	Normalización del piso de ventas municipal por encima de los \$300.000 COP .
Calidad de Datos / Gobierno BI	Inconsistencias en el campo monto_total y fechas de operación.	Automatizar las validaciones de entrada en los sistemas POS/móviles de los preventistas para evitar la imputación de datos en etapa ETL.	Reducción del 100% de datos modificados/imputados en las auditorías de BD.

++


3. Conclusión para la Junta Directiva

El modelo relacional $3FN$ y los análisis visuales implementados demuestran que **Gaseosas Poderosas** posee un negocio rentable con núcleos consolidados en la región andina. Sin embargo, la compañía depende excesivamente de pocos departamentos (Antioquia y Boyacá concentran cerca del 37% de los ingresos).

Ejecutar las acciones correctivas en el Valle del Cauca y equilibrar el portafolio mediante ventas cruzadas transformará los datos atípicos negativos en oportunidades inmediatas de facturación.

12.- Diagrama de flujo del programa Python de procesamiento ETL

.



13.- Conclusiones INDIVIDUALES

Mariana López Díaz

- **Impacto en el Proceso de Aprendizaje Técnico:** El desarrollo de este proyecto me permitió consolidar de forma práctica la diferencia entre un flujo de datos teórico y un entorno de producción real. Comprender el impacto directo que tienen los datos "sucios" (fechas heterogéneas, nulos o IDs desalineados) sobre las métricas del negocio fortaleció mi capacidad para diseñar algoritmos de limpieza en Python e implementar estructuras relacionales sólidas en PostgreSQL.

- **Aporte a la Vida Académica y Profesional:** A nivel académico, este ejercicio integró habilidades de modelado (notación de Chen), programación en Python y consultas avanzadas en SQL, otorgándome una visión holística del ciclo de vida del dato. En el ámbito profesional, me prepara para asumir roles de Ingeniería de Datos o Analítica BI, donde la trazabilidad, el gobierno de datos (mediante campos de auditoría) y la optimización de consultas son competencias críticas para la toma de decisiones estratégicas.

Sara Ximena Machado.

- **Impacto en el Proceso de Aprendizaje Técnico:** Esta actividad me permitió profundizar en la importancia del modelado relacional riguroso y en la correcta aplicación de la tercera forma normal (3FN) para evitar redundancias en un entorno transaccional. Asimismo, la construcción e interpretación de gráficos analíticos (Pareto y distribuciones porcentuales) a partir de consultas SQL estructuradas.
- **Aporte a la Vida Académica y Profesional:** En la vida académica, el proyecto consolidó mi criterio para conectar el diseño conceptual de bases de datos con la presentación gráfica e interpretación de indicadores de rendimiento. De cara al campo profesional, esta actividad me proporcionó herramientas clave para desempeñarme en roles de Análisis de Datos, Inteligencia de Negocios (BI) o Consultoría Tecnológica, donde la precisión en la extracción de datos y la capacidad para comunicar hallazgos técnicos a nivel directivo son fundamentales.

Jhorman Vallejo

- **Impacto en el Proceso de Aprendizaje Técnico:** Esta actividad me permitió entender, desde la parte que me correspondió, la diferencia entre un archivo del DANE, donde los datos vienen separados por comas, y una información ya ordenada para poder consultarla. Al pasar esos datos a la base y corregir registros con fechas mal escritas, cantidades en cero o negativas y códigos vacíos, vi que un error pequeño cambia los resultados que después revisa el equipo. También aprendí a dejar anotado qué dato se corrigió y por qué.
- **Aporte a la Vida Académica y Profesional:** En la vida académica, el ejercicio me ayudó a unir la programación con las consultas, entendiendo que preparar bien los datos es la base del análisis y de los gráficos del grupo. De cara al campo profesional, me acerca a labores de apoyo en el manejo de información, donde hay que dejar los datos claros y confiables para que otras personas puedan leer los resultados y tomar decisiones.

14.- Video explicativo del desarrollo completo de la tarea por parte de los miembros del equipo

https://drive.google.com/file/d/1wGjklRdIL5yK7F1xJJzjMJqsbBZ5Tmd/view?usp=drive_link